Inteligencia artificial

Gruintal Polanco, Guillermo Cristian

Q-learning en Cliff Walking

2. Reporte de resultados

¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

En el problema de Cliff Walking, cada transición tiene una recompensa negativa constante de -1. En un proceso de decisión donde todas las transiciones tienen costo uniforme, lo óptimo equivale a minimizar la cantidad total de pasos necesarios para ir del estado inicial a la meta, que en este caso es 13 por la orilla.

¿Por qué la curva de entrenamiento queda por debajo de -13 aunque la política greedy ya sea óptima?

Porque la política tiene una probabilidad de hacer una acción aleatoria (ϵ-greedy), y en el camino de mayor recompensa, que es caminar por el acantilado, existen los casos donde el agente se cae y recibe una penalización severa, por lo que se ve afectada la recompensa acumulada por episodio.

En el paso que cae al acantilado, ¿cuál es s' en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

Cuando un agente se cae en el acantilado, el estado siguiente s' es el estado inicial; no se considera estado final porque, tal como fue planteado el problema original, el episodio continúa desde la posición de inicio y se recibe una penalización de -100.